Введение в RNN Рекуррентные Нейронные Сети для начинающих

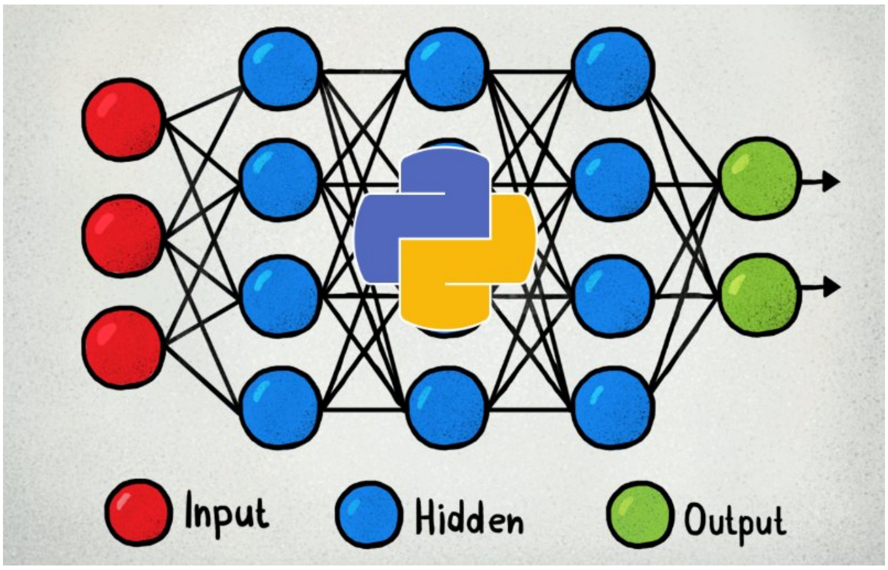

В данной статье мы рассмотрим, что такое **рекуррентные нейронные сети** и как создать нейронную сеть с нуля в Python.

Содержание

Рекуррентные нейронные сети (RNN) — это тип нейронных сетей, которые специализируются на обработке последовательностей. Зачастую их используют в таких задачах, как обработка естественного языка (Natural Language Processing) из-за их эффективности в **анализе текста**. В данной статье мы наглядно рассмотрим рекуррентные **нейронные сети**, поймем принцип их работы, а также создадим одну сеть в Python, используя numpy.

Данная статья подразумевает наличие у читателя базовых знаний о нейронных сетях. Будет не лишним прочитать от том как создать нейронную сеть в Python, в которой показаны простые примеры использования нейронов в Python.

Приступим!

Зачем нужны рекуррентные нейронные сети

Один из нюансов работы с **нейронными сетями** (а также CNN) заключается в том, что они работают с предварительно заданными параметрами. Они принимают входные данные с фиксированными размерами и выводят результат, который также является фиксированным. Плюс **рекуррентных нейронных сетей**, или RNN, в том, что они обеспечивают последовательности с вариативными длинами как для входа, так и для вывода. Вот несколько примеров того, как может выглядеть **рекуррентная нейронная сеть**:

Учебники по Python

- Django для начинающих
- Flask уроки для начинающих
- PyCairo
- Python 3 для начинающих
- Python Новости
- REST API
- Tkinter
- wxPython
- Алгоритмы
- Анализ кода
- Асинхронное программирование
- Базы данных
- Веб-программирование
- Видеоуроки
- Графический Интерфейс
- Декораторы
- Нейронные сети
- Обработка данных
- Продвинутый
- Работа с PDF
- Работа с изображениями
- Разное из мира IT
- Создание ботов
- Создание игр на PyGame
- Создание игр на Python
- Создание сайта
- Сравнение с языками программирования
- Установка и настройка
- Хакинг

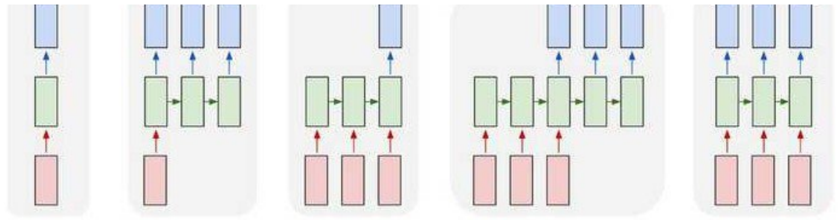

Входные данные отмечены красным, нейронная сеть RNN — зеленым, а вывод — синим.

Способность обрабатывать последовательности делает **рекуррентные нейронные сети RNN** весьма полезными. Области использования:

- **Машинный перевод** (пример Google Translate) выполняется при помощи нейронных сетей с принципом «многие ко многим». Оригинальная последовательность текста подается в рекуррентную нейронную сеть, которая затем создает переведенный текст в качестве результата вывода;
- **Анализ настроений** часто выполняется при помощи рекуррентных нейронных сетей с принципом «многие к одному». *Этот отзыв положительный или отрицательный?* Такая постановка является одним из примеров анализа настроений. Анализируемый текст подается нейронную сеть, которая затем создает единственную классификацию вывода. Например — *Этот отзыв положительный*.

Далее в статье будет показан пример **создания рекуррентной нейронной сети** по схеме «многие к одному» для анализа настроений.

Создание рекуррентной нейронной сети на примере

Представим, что у нас есть нейронная сеть, которая работает по принципу «*многое ко многим*». Входные данные — $x_0, x_1, \dots x_n$, а результаты вывода — $y_0, y_1, \dots y_n$. Данные x_i и y_i являются векторами и могут быть произвольных размеров.

Рекуррентные нейронные сети **RNN** работают путем итерированного обновления скрытого состояния h, которое является **вектором**, что также может иметь произвольный размер. Стоит учитывать, что на любом заданном этапе t:

1. Следующее скрытое состояние h_t подсчитывается при помощи предыдущего h_{t-1} и следующим вводом x_t;
2. Следующий вывод y_t подсчитывается при помощи h_t.

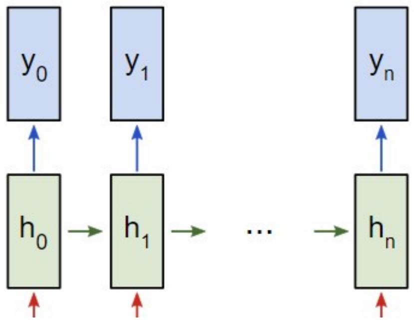

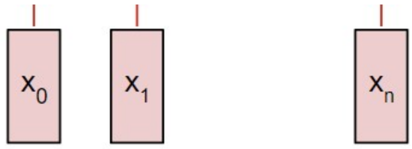

Рекуррентная нейронная сеть RNN многие ко многим

Вот что делает **нейронную сеть рекуррентной**: на каждом шаге она использует один и тот же вес. Говоря точнее, типичная классическая рекуррентная нейронная сеть использует только три набора параметров веса для выполнения требуемых подсчетов:

- W_{xh} используется для всех связок $x_t \rightarrow h_t$
- W_{hh} используется для всех связок $h_{t-1} \rightarrow h_t$
- W_{hy} используется для всех связок $h_t \rightarrow y_t$

Для рекуррентной нейронной сети мы также используем два смещения:

- b_h добавляется при подсчете h_t
- b_y добавляется при подсчете y_t

Вес будет представлен как матрица, а смещение как вектор. В данном случае **рекуррентная нейронная сеть** состоит их трех параметров веса и двух смещений.

Следующие уравнения являются компактным представлением всего вышесказанного:

$$h_t = \tanh(W_{xh}x_t + W_{hh}h_{t-1} + b_h)$$

$$y_t = W_{hy}h_t + b_y$$

Разбор уравнений лучше не пропускать. Остановитесь на минутку и изучите их внимательно. Помните, что вес — это матрица, а другие переменные являются векторами.

Говоря о весе, мы используем **матричное умножение**, после чего векторы вносятся в конечный результат. Затем применяется гиперболическая функция в качестве функции активации первого уравнения. Стоит иметь в виду, что другие методы активации, например, сигмоиду, также можно использовать.

> Не знаете, что такое функция активации? Вы можете ознакомиться с ними в вводной статье о нейронных сетях. Для оптимальной работы это важно.

Поставление задачи для рекуррентной нейронной сети

К текущему моменту мы смогли реализовать рекуррентную нейронную сеть **RNN с нуля**. Она должна выполнить простой анализ настроения. В дальнейшем примере мы попросим сеть определить, будет заданная строка нести позитивный или негативный характер.

Вот несколько примеров из небольшого набора данных, который был собран для данной статьи:

Текст	**Позитивный?**
Я хороший	Да
Я плохой	Нет
Это очень хорошо	Да
Это неплохо	Да
Я плохой, а не хороший	Нет
Я несчастен	Нет
Это было хорошо	Да
Я чувствую себя неплохо, мне не грустно	Да

Составление плана для нейронной сети

В следующем примере будет использована классификация рекуррентной сети «многие к одному». Принцип ее использования напоминает работу схемы «многие ко многим», что была описана ранее. Однако на этот раз будет задействовано только скрытое состояние для одного пункта вывода y:

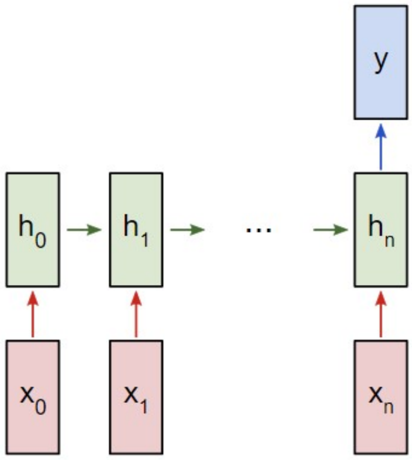

Рекуррентная нейронная сеть RNN многие к одному

Каждый x_i будет вектором, представляющим определенное слово из текста. Вывод y будет вектором, содержащим два числа. Одно представляет позитивное настроение, а второе — негативное. Мы используем функцию Softmax, чтобы превратить эти значения в вероятности, и в конечном счете выберем между позитивным и негативным.

Приступим к созданию нашей рекуррентной нейронной сети.

Предварительная обработка рекуррентной нейронной сети RNN

Упомянутый ранее набор данных состоит из двух словарей Python:

```python
train_data = {
    'good': True,
    'bad': False,
    # ... больше данных
}

test_data = {
    'this is happy': True,
    'i am good': True,
    # ... больше данных
}
```

True = Позитивное, False = Негативное

Для получения данных в удобном формате потребуется сделать определенную предварительную обработку. Для начала необходимо создать словарь в Python из всех слов, которые употребляются в наборе данных:

```python
from data import train_data, test_data

# Создание словаря
vocab = list(set([w for text in train_data.keys() for w in text.split(' ')]))
vocab_size = len(vocab)

print('%d unique words found' % vocab_size) # найдено 18 уникальных слов
```

`vocab` теперь содержит список всех слов, которые употребляются как минимум в одном учебном тексте. Далее присвоим каждому слову из `vocab` индекс типа `integer` (целое число).

```python
# Назначить индекс каждому слову
word_to_idx = { w: i for i, w in enumerate(vocab) }
idx_to_word = { i: w for i, w in enumerate(vocab) }

print(word_to_idx['good']) # 16 (это может измениться)
print(idx_to_word[0]) # грустно (это может измениться)
```

Теперь можно отобразить любое заданное слово при помощи индекса целого числа. Это очень важный пункт, так как:

> Рекуррентная нейронная сеть не различает слов — только числа.

Напоследок напомним, что каждый ввод x_i для рассматриваемой рекуррентной нейронной сети является вектором. Мы будем использовать веторы, которые представлены в виде унитарного кода. Единица в каждом векторе будет находиться в соответствующем целочисленном индексе слова.

Так как в словаре 18 уникальных слов, каждый x_i будет 18-мерным унитарным вектором.

```python
import numpy as np


def createInputs(text):
    '''
    Возвращает массив унитарных векторов
    которые представляют слова в введенной строке текста
    - текст является строкой string
    - унитарный вектор имеет форму (vocab_size, 1)
    '''

    inputs = []
    for w in text.split(' '):
        v = np.zeros((vocab_size, 1))
        v[word_to_idx[w]] = 1
        inputs.append(v)

    return inputs
```

Мы используем `createInputs()` позже для создания входных данных в виде векторов и последующей их передачи в рекуррентную нейронную сеть RNN.

Фаза прямого распространения нейронной сети

Пришло время для **создания рекуррентной нейронной сети**. Начнем инициализацию с тремя параметрами веса и двумя смещениями.

```python
import numpy as np
from numpy.random import randn


class RNN:
    # Классическая рекуррентная нейронная сеть

    def __init__(self, input_size, output_size, hidden_size=64):
        # Вес
        self.Whh = randn(hidden_size, hidden_size) / 1000
        self.Wxh = randn(hidden_size, input_size) / 1000
        self.Why = randn(output_size, hidden_size) / 1000

        # Смещения
        self.bh = np.zeros((hidden_size, 1))
        self.by = np.zeros((output_size, 1))
```

Обратите внимание: для того, чтобы убрать внутреннюю вариативность весов, мы делим на 1000. Это не самый лучший способ инициализации весов, но он довольно простой, подойдет для новичков и неплохо работает для данного примера.

Для инициализации веса из стандартного нормального распределения мы используем np.random.randn().

Затем мы реализуем прямую передачу рассматриваемой нейронной сети. Помните первые два уравнения, рассматриваемые ранее?

$$h_t = \tanh(W_{xh}x_t + W_{hh}h_{t-1} + b_h)$$

$$y_t = W_{hy}h_t + b_y$$

Эти же уравнения, реализованные в коде:

```python
```

```python
class RNN:
    # ...

    def forward(self, inputs):
        '''
        Выполнение передачи нейронной сети при помощи входных данных
        Возвращение результатов вывода и скрытого состояния
        Вывод - это массив одного унитарного вектора с формой (input_size, 1)
        '''
        h = np.zeros((self.Whh.shape[0], 1))

        # Выполнение каждого шага в нейронной сети RNN
        for i, x in enumerate(inputs):
            h = np.tanh(self.Wxh @ x + self.Whh @ h + self.bh)

        # Compute the output
        y = self.Why @ h + self.by

        return y, h
```

Довольно просто, не так ли? Обратите внимание на то, что мы инициализировали `h` для нулевого вектора в первом шаге, так как у нас нет предыдущего `h`, который теперь можно использовать.

Давайте попробуем следующее:

Python

```python
# ...

def softmax(xs):
    # Применение функции Softmax для входного массива
    return np.exp(xs) / sum(np.exp(xs))


# Инициализация нашей рекуррентной нейронной сети RNN
rnn = RNN(vocab_size, 2)


inputs = createInputs('i am very good')
out, h = rnn.forward(inputs)
probs = softmax(out)
print(probs) # [[0.50000095], [0.49999905]]
```

Наша рекуррентная нейронная сеть работает, однако ее с трудом можно назвать полезной. Давайте исправим этот недочет.

Фаза обратного распространения нейронной сети

Для тренировки рекуррентной нейронной сети будет использована функция потери. Здесь будет использована **потеря перекрестной энтропии**, которая в большинстве случаев совместима с функцией **Softmax**. Формула для подсчета:

$$L = -\ln(p_c)$$

Здесь p_c является предсказуемой вероятностью рекуррентной нейронной сети для класса `correct` (позитивный или негативный). Например, если позитивный текст предсказывается рекуррентной нейронной сетью как позитивный текст на 90%, то потеря составит:

$$L = -\ln(0.90) = 0.105$$

При наличии параметров потери можно натренировать нейронную сеть таким образом, чтобы она использовала **градиентный спуск для минимизации потерь**. Следовательно, здесь понадобятся градиенты.

Обратите внимание: следующий раздел подразумевает наличие у читателя базовых знаний об многовариантном исчислении. Вы можете пропустить несколько абзацев, однако мы рекомендуем все пробежаться по ним глазами. По мере получения новых данных код будет дополняться, и объяснения станут понятнее.

Оригиналы всех кодов, которые использованы в данной инструкции, доступны на GitHub.

Готовы? Продолжим!

Параметры рассматриваемой нейронной сети

Параметры данных, которые будут использованы в дальнейшем:

- `y` — необработанные входные данные нейронной сети;
- `p` — конечная вероятность: `p = softmax(y)`;
- `c` — истинная метка определенного образца текста, так называемый «правильный» класс;
- `L` — потеря перекрестной энтропии: `L = -ln(`p_c`)`;
- W_{xh}, W_{hh} и W_{hy} — три матрицы веса в рассматриваемой нейронной сети;
- b_h и b_y — два вектора смещения в рассматриваемой рекуррентной нейронной сети **RNN**.

Установка

Следующим шагом будет **настройка фазы прямого распространения**. Это необходимо для кеширования отдельных данных, которые будут использоваться в фазе обратного распространения нейронной сети. Параллельно с этим можно будет установить основной скелет для фазы обратного распространения. Это будет выглядеть следующим образом:

```python
class RNN:
    # ...

    def forward(self, inputs):
        '''
        Выполнение фазы прямого распространения нейронной сети с
        использованием введенных данных.
        Возврат итоговой выдачи и скрытого состояния.
        - Входные данные в массиве однозначного вектора с формой (input_size,
        '''
        h = np.zeros((self.Whh.shape[0], 1))

        self.last_inputs = inputs
        self.last_hs = { 0: h }

        # Выполнение каждого шага нейронной сети RNN
        for i, x in enumerate(inputs):
            h = np.tanh(self.Wxh @ x + self.Whh @ h + self.bh)
            self.last_hs[i + 1] = h

        # Подсчет вывода
        y = self.Why @ h + self.by

        return y, h

    def backprop(self, d_y, learn_rate=2e-2):
        '''
        Выполнение фазы обратного распространения нейронной сети RNN.
        - d_y (dL/dy) имеет форму (output_size, 1).
        - learn_rate является вещественным числом float.
        '''
        pass
```

Градиенты

Настало время математики! Начнем с вычисления $\frac{\partial L}{\partial y}$. Что нам известно:

$$L = -\ln(p_c) = -\ln(\text{softmax}(y_c))$$

Здесь используется фактическое значение $\frac{\partial L}{\partial y}$, а также применяется **дифференцирование сложной функции**. Результат следующий:

$$\frac{\partial L}{\partial y_i} = \begin{cases} p_i & \text{if } i \neq c \\ p_i - 1 & \text{if } i = c \end{cases}$$

К примеру, если `p = [0.2, 0.2, 0.6]`, а корректным классом является `c = 0`, то конечным результатом будет значение $\frac{\partial L}{\partial y}$ `= [-0.8, 0.2, 0.6]`. Данное выражение несложно перевести в код:

```python
# Цикл для каждого примера тренировки
for x, y in train_data.items():
    inputs = createInputs(x)
    target = int(y)

    # Прямое распространение
    out, _ = rnn.forward(inputs)
    probs = softmax(out)

    # Создание dL/dy
    d_L_d_y = probs
    d_L_d_y[target] -= 1

    # Обратное распространение
    rnn.backprop(d_L_d_y)
```

Отлично. Теперь разберемся с градиентами для W_{hy} и b_y, которые используются только для перехода конечного скрытого состояния в результат вывода рассматриваемой **нейронной сети RNN**. Используем следующие данные:

$$\frac{\partial L}{\partial W_{hy}} = \frac{\partial L}{\partial y} * \frac{\partial y}{\partial W_{hy}}$$

$$y = W_{hy} h_n + b_y$$

Здесь h_n является конечным скрытым состоянием. Таким образом:

$$\frac{\partial y}{\partial W_{hy}} = h_n$$

$$\frac{\partial L}{\partial W_{hy}} = \boxed{\frac{\partial L}{\partial y} h_n}$$

Аналогичным способом вычисляем:

$$\frac{\partial y}{\partial b_y} = 1$$

$$\frac{\partial L}{\partial b_y} = \boxed{\frac{\partial L}{\partial y}}$$

Теперь можно приступить к реализации `backprop()`.

```python
class RNN:
    # ...

    def backprop(self, d_y, learn_rate=2e-2):
        '''
        Выполнение фазы обратного распространения нейронной сети RNN.
        - d_y (dL/dy) имеет форму (output_size, 1).
        - learn_rate является вещественным числом float.
        '''
        n = len(self.last_inputs)

        # Подсчет dL/dWhy и dL/dby.
        d_Why = d_y @ self.last_hs[n].T
        d_by = d_y
```

Напоминание: мы создали `self.last_hs` в `forward()` в предыдущих примерах.

Наконец, нам понадобятся градиенты для W_{hh}, W_{xh}, и b_h, которые использовались в каждом шаге нейронной сети. У нас есть:

$$\frac{\partial L}{\partial W_{xh}} = \frac{\partial L}{\partial y} \sum_t \frac{\partial y}{\partial h_t} * \frac{\partial h_t}{\partial W_{xh}}$$

Изменение W_{xh} влияет не только на каждый h_t, но и на все y , что, в свою очередь, приводит к изменениям в L. Для того, чтобы полностью подсчитать градиент W_{xh}, необходимо провести обратное распространение через все временные шаги. Его также называют **Обратным распространением во времени**, или Backpropagation Through Time (BPTT):

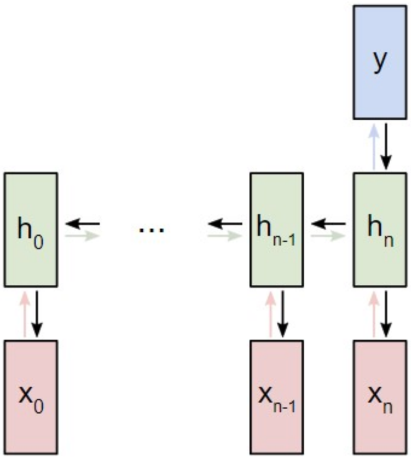

Обратное распространение во времени

W_{xh} используется для всех прямых ссылок $x_t \rightarrow h_t$, поэтому нам нужно провести обратное распространение назад к каждой из этих ссылок.

Приблизившись к заданному шагу t, потребуется подсчитать $\frac{\partial h_t}{\partial W_{xh}}$:

$$h_t = \tanh(W_{xh} x_t + W_{hh} h_{t-1} + b_h)$$

Производная гиперболической функции $\tanh$ нам уже известна:

$$\frac{d \tanh(x)}{dx} = 1 - \tanh^2(x)$$

Используем **дифференцирование сложной функции**, или цепное правило:

$$\frac{\partial h_t}{\partial W_{xh}} = \boxed{(1 - h_t^2) x_t}$$

Аналогичным способом вычисляем:

$$\frac{\partial h_t}{\partial W_{hh}} = \boxed{(1 - h_t^2) h_{t-1}}$$

$$\frac{\partial h_t}{\partial b_h} = \boxed{(1 - h_t^2)}$$

Последнее нужное значение — $\frac{\partial y}{\partial h_t}$. Его можно подсчитать рекурсивно:

$$\begin{aligned} \frac{\partial y}{\partial h_t} &= \frac{\partial y}{\partial h_{t+1}} * \frac{\partial h_{t+1}}{\partial h_t} \\ &= \frac{\partial y}{\partial h_{t+1}} (1 - h_t^2) W_{hh} \end{aligned}$$

Реализуем обратное распространение во времени, или BPTT, отталкиваясь от скрытого состояния в качестве начальной точки. Далее будем работать в обратном порядке. Поэтому на момент подсчета

$\frac{\partial y}{\partial h_t}$ значение $\frac{\partial y}{\partial h_{t+1}}$ будет известно. Исключением станет только последнее скрытое состояние h_n:

$$\frac{\partial y}{\partial h_n} = W_{hy}$$

Теперь у нас есть все необходимое, чтобы наконец реализовать обратное распространение во времени **BPTT** и закончить `backprop()`:

```python
class RNN:
    # ...

    def backprop(self, d_y, learn_rate=2e-2):
        '''
        Выполнение фазы обратного распространения RNN.
        - d_y (dL/dy) имеет форму (output_size, 1).
        - learn_rate является вещественным числом float.
        '''
        n = len(self.last_inputs)

        # Вычисление dL/dWhy и dL/dby.
        d_Why = d_y @ self.last_hs[n].T
        d_by = d_y

        # Инициализация dL/dWhh, dL/dWxh, и dL/dbh к нулю.
        d_Whh = np.zeros(self.Whh.shape)
        d_Wxh = np.zeros(self.Wxh.shape)
        d_bh = np.zeros(self.bh.shape)

        # Вычисление dL/dh для последнего h.
        d_h = self.Why.T @ d_y

        # Обратное распространение во времени.
        for t in reversed(range(n)):
            # Среднее значение: dL/dh * (1 - h^2)
            temp = ((1 - self.last_hs[t + 1] ** 2) * d_h)

            # dL/db = dL/dh * (1 - h^2)
            d_bh += temp

            # dL/dWhh = dL/dh * (1 - h^2) * h_{t-1}
            d_Whh += temp @ self.last_hs[t].T

            # dL/dWxh = dL/dh * (1 - h^2) * x
            d_Wxh += temp @ self.last_inputs[t].T

            # Далее dL/dh = dL/dh * (1 - h^2) * Whh
            d_h = self.Whh @ temp

        # Отсекаем, чтобы предотвратить разрыв градиентов.
        for d in [d_Wxh, d_Whh, d_Why, d_bh, d_by]:
            np.clip(d, -1, 1, out=d)

        # Обновляем вес и смещение с использованием градиентного спуска.
        self.Whh -= learn_rate * d_Whh
        self.Wxh -= learn_rate * d_Wxh
        self.Why -= learn_rate * d_Why
        self.bh -= learn_rate * d_bh
        self.by -= learn_rate * d_by
```

Моменты, на которые стоит обратить внимание:

- Мы объединили $\frac{\partial L}{\partial y} * \frac{\partial y}{\partial h}$ в $\frac{\partial L}{\partial h}$ для удобства;
- Мы постоянно обновляем переменную `d_h`, которая держит самую последнюю версию $\frac{\partial y}{\partial h_{t+1}}$, что требуется для подсчета $\frac{\partial L}{\partial h_t}$;
- Закончив с обратным распространением во времени BPTT, мы используем np.clip() на значениях градиента ниже `-1` или выше `1`. Это поможет избавиться от проблемы со **взрывными градиентами**. Такое случается, когда градиенты становятся слишком большими из-за огромного количества умноженных параметров. Взрыв, а также исчезновение градиентов не считается редкостью для классических рекуррентных нейронных сетей. Более сложные **рекуррентные нейронные сети**, например LSTM, лучше подойдут для их обработки.
- Когда все градиенты подсчитаны, мы обновляем параметры веса и смещения, используя градиентный спуск.

Мы сделали это! Наша **рекуррентная нейронная сеть** готова.

Тестирование рекуррентной нейронной сети

Наконец настал тот момент, которого мы так долго ждали — протестируем готовую рекуррентную нейронную сеть.

Для начала, напишем вспомогательную функцию для обработки данных рассматриваемой рекуррентной нейронной сети:

Python

```python
import random


def processData(data, backprop=True):
    '''
    Возврат потери рекуррентной нейронной сети и точности для данных
    - данные представлены как словарь, что отображает текст как True или Fals
    - backprop определяет, нужно ли использовать обратное распределение
    '''
    items = list(data.items())
    random.shuffle(items)

    loss = 0
    num_correct = 0

    for x, y in items:
        inputs = createInputs(x)
        target = int(y)

        # Прямое распределение
        out, _ = rnn.forward(inputs)
        probs = softmax(out)

        # Вычисление потери / точности
        loss -= np.log(probs[target])
        num_correct += int(np.argmax(probs) == target)

        if backprop:
            # Создание dL/dy
            d_L_d_y = probs
            d_L_d_y[target] -= 1

            # Обратное распределение
            rnn.backprop(d_L_d_y)

    return loss / len(data), num_correct / len(data)
```

Теперь можно написать цикл для **тренировки сети**:

Python

```python
# Цикл тренировки
for epoch in range(1000):
    train_loss, train_acc = processData(train_data)

    if epoch % 100 == 99:
        print('--- Epoch %d' % (epoch + 1))
        print('Train:\tLoss %.3f | Accuracy: %.3f' % (train_loss, train_acc))

        test_loss, test_acc = processData(test_data, backprop=False)
        print('Test:\tLoss %.3f | Accuracy: %.3f' % (test_loss, test_acc))
```

Результат вывода `main.py` выглядит следующим образом:

Shell

```
--- Epoch 100
Train:  Loss 0.688 | Accuracy: 0.517
Test:   Loss 0.700 | Accuracy: 0.500
--- Epoch 200
Train:  Loss 0.680 | Accuracy: 0.552
Test:   Loss 0.717 | Accuracy: 0.450
--- Epoch 300
Train:  Loss 0.593 | Accuracy: 0.655
Test:   Loss 0.657 | Accuracy: 0.650
--- Epoch 400
Train:  Loss 0.401 | Accuracy: 0.810
Test:   Loss 0.689 | Accuracy: 0.650
--- Epoch 500
Train:  Loss 0.312 | Accuracy: 0.862
Test:   Loss 0.693 | Accuracy: 0.550
--- Epoch 600
Train:  Loss 0.148 | Accuracy: 0.914
Test:   Loss 0.404 | Accuracy: 0.800
--- Epoch 700
Train:  Loss 0.008 | Accuracy: 1.000
Test:   Loss 0.016 | Accuracy: 1.000
--- Epoch 800
Train:  Loss 0.004 | Accuracy: 1.000
Test:   Loss 0.007 | Accuracy: 1.000
--- Epoch 900
Train:  Loss 0.002 | Accuracy: 1.000
Test:   Loss 0.004 | Accuracy: 1.000
--- Epoch 1000
Train:  Loss 0.002 | Accuracy: 1.000
Test:   Loss 0.003 | Accuracy: 1.000
```

Неплохо для **рекуррентной нейронной сети**, которую мы построили сами!

Хотите поэкспериментировать с этим кодом сами? Можете запустить данную рекуррентную нейронную сеть RNN у себя в браузере. Она также доступна на GitHub.

Подведем итоги

Вот и все, пошаговое **руководство по рекуррентным нейронным сетям** на этом закончено. Мы узнали, что такое RNN, как они работают, почему они полезны, как их создавать и тренировать. Это очень малый аспект мира нейронных сетей. При желании вы можете продолжить изучение темы самостоятельно, используя следующие ресурсы:

- Подробнее ознакомьтесь с LTSM. Это долгая краткосрочная память, которая характерна более мощной архитектурой рекуррентных нейронных сетей. Будет не лишним ознакомиться с управляемым рекуррентными блоками, или **GRU**. Это наиболее популярная вариация **LTSM**;
- Поэкспериментируйте с более крупными и сложными RNN. Для этого используйте подходящие ML библиотеки, например, Tensorflow, Keras или PyTorch;
- Прочтите о двунаправленных нейронных сетях, которые обрабатывают последовательности как в прямом, так и в обратном направлении. Это позволяет получить больше информации на уровне вывода;
- Ознакомьтесь с векторными представлением слов. Для этого можно использовать GloVe или Word2Vec;
- Познакомьтесь поближе с Natural Language Toolkit (NLTK), популярной библиотекой Python для работы с данными на языках, которые используют люди, а не машины.

Благодарим за внимание!

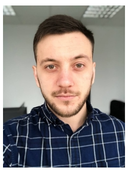

Vasile Buldumac

Являюсь администратором нескольких порталов по обучению языков программирования Python, Golang и Kotlin. В составе небольшой команды единомышленников, мы занимаемся популяризацией языков программирования на русскоязычную аудиторию. Большая часть статей была адаптирована нами на русский язык и распространяется бесплатно.

E-mail: vasile.buldumac@ati.utm.md

Образование

Universitatea Tehnică a Moldovei (*utm.md*)

- 2014 — 2018 Технический Университет Молдовы, ИТ-Инженер. Тема дипломной работы *«Автоматизация покупки и продажи криптовалюты используя технический анализ»*
- 2018 — 2020 Технический Университет Молдовы, Магистр, Магистерская диссертация *«Идентификация человека в киберпространстве по фотографии лица»*